

INSTITUTO MAUÁ DE TECNOLOGIA

Pós-graduação em Ciência de Dados e Inteligência Artificial

Disciplina: Engenharia de Dados

Projeto Final

Pipeline de Engenharia de Dados para IA aplicada a PMEs

Previsão de demanda, análise de churn e recomendação de ações comerciais

Integrantes

Raí van der Meer Oliveira Neves — RA: 20.01188-0

Rafael de Almeida Valente — RA: 20.01293-4

São Caetano do Sul

2026

Sumário

1. Resumo executivo
2. Introdução
3. Problema de negócio
4. Objetivo do pipeline
5. Fontes de dados propostas
6. Arquitetura geral da solução
7. Camada Bronze
8. Camada Silver
9. Camada Gold
10. Uso dos dados em algoritmos de IA
11. Qualidade de dados, testes e governança
12. Orquestração e operação
13. Conclusão

1. Resumo executivo

Este projeto propõe a arquitetura de um pipeline de Engenharia de Dados para pequenas e médias empresas (PMEs) que desejam utilizar Inteligência Artificial em processos comerciais, operacionais e de relacionamento com clientes. A proposta considera o cenário recorrente em PMEs: dados distribuídos entre sistemas de vendas, planilhas, CRM, canais de atendimento e registros operacionais, com baixo grau de integração e pouca padronização.

O pipeline foi desenhado seguindo a arquitetura Medallion, com camadas Bronze, Silver e Gold. A camada Bronze preserva os dados brutos e rastreáveis; a camada Silver realiza limpeza, padronização e integração; e a camada Gold disponibiliza datasets curados e preparados para algoritmos de IA, como previsão de demanda, previsão de churn, segmentação de clientes, classificação de atendimentos e recomendação de ações comerciais.

A solução foi estruturada com tecnologias open source e compatíveis com os conceitos da disciplina: Docker e Docker Compose para containerização, MinIO como Data Lake compatível com S3, Airbyte e dlt para ingestão, Parquet como formato analítico, dbt, DuckDB ou Spark para transformação, Airflow para orquestração e Great Expectations ou testes dbt para qualidade de dados. O foco do trabalho não é implementar o pipeline, mas descrever suas funcionalidades, camadas, tipos de dados, padrões de qualidade e tecnologias necessárias para viabilizar o uso de IA em PMEs.

2. Introdução

A Engenharia de Dados pode ser entendida como a prática de projetar, construir e manter sistemas e infraestrutura para coletar, armazenar e processar dados em escala. No contexto de projetos de IA, ela é a base que permite transformar dados brutos, dispersos e muitas vezes desorganizados em conjuntos de dados confiáveis e utilizáveis para análise, tomada de decisão e treinamento de modelos.

Em pequenas e médias empresas, o desafio é especialmente relevante. Muitas decisões comerciais e operacionais ainda dependem de planilhas isoladas, relatórios manuais ou informações armazenadas em sistemas que não se comunicam entre si. Mesmo quando existem dados suficientes para gerar inteligência, a falta de padronização, qualidade e rastreabilidade impede seu uso eficiente em modelos preditivos.

Dessa forma, este projeto propõe uma arquitetura de pipeline de dados voltada para PMEs que desejam aplicar IA de forma prática. A proposta busca organizar o ciclo de vida dos dados desde a ingestão até a geração de datasets prontos para algoritmos, respeitando boas práticas de Data Lakehouse, governança, qualidade e orquestração.

3. Problema de negócio

O problema central abordado é a dificuldade das PMEs em transformar seus dados operacionais em insumos confiáveis para Inteligência Artificial. Mesmo negócios com bom volume de vendas, atendimento e relacionamento com clientes costumam enfrentar limitações como:

- dados de clientes, vendas e estoque espalhados em sistemas diferentes;
- planilhas manuais sem controle de versão ou padronização;
- histórico de atendimento em canais como WhatsApp sem estrutura analítica;
- ausência de regras claras de qualidade e governança de dados;
- baixa rastreabilidade sobre origem, atualização e transformação dos dados;
- dificuldade de gerar bases consistentes para modelos de IA.

Esse cenário reduz a capacidade da empresa de prever demanda, identificar clientes com risco de abandono, segmentar públicos, melhorar o atendimento e recomendar ações comerciais. O pipeline proposto resolve esse problema ao estruturar um fluxo de dados automatizável, auditável e preparado para consumo analítico e preditivo.

4. Objetivo do pipeline

O objetivo geral do projeto é descrever uma arquitetura de Engenharia de Dados capaz de preparar dados de PMEs para uso em algoritmos de IA, respeitando as camadas Bronze, Silver e Gold e utilizando ferramentas adequadas à construção de um Data Lakehouse.

Objetivos específicos:

- mapear fontes de dados relevantes para PMEs, incluindo fontes estruturadas, semiestruturadas e não estruturadas;
- definir mecanismos de ingestão em lote e, quando necessário, em fluxo contínuo;
- preservar dados brutos na camada Bronze com metadados de rastreabilidade;
- aplicar limpeza, padronização, deduplicação e integração na camada Silver;
- modelar conjuntos de dados analíticos e features na camada Gold;
- descrever como os dados finais serão utilizados por algoritmos de IA;
- incluir práticas de qualidade, governança, segurança e orquestração.

5. Fontes de dados propostas

A proposta considera múltiplas fontes de dados, pois a avaliação do projeto valoriza a diversidade de origens e a adequação das transformações necessárias para cada tipo. As fontes abaixo representam um cenário realista de uma PME com operação comercial, controle de estoque e atendimento digital.

Fonte	Tipo de dado	Exemplos de campos	Frequência sugerida
ERP / sistema de vendas	Estruturado, banco relacional	id_pedido, id_cliente, data_venda, produto, quantidade, valor, desconto, vendedor	Diária ou horária
Sistema de estoque	Estruturado, banco relacional ou CSV	id_produto, saldo_atual, entrada, saída, ruptura, estoque_mínimo	Horária ou diária
CRM / funil comercial	Estruturado ou via API	lead_id, origem, etapa_funil, probabilidade, responsável, data_contato	Diária
WhatsApp / atendimento	Semiestruturado, JSON/API	telefone, timestamp, mensagem, atendente, intenção, status, sentimento	Quase tempo real ou diária
Planilhas comerciais	Arquivos CSV/Excel	metas, preços, campanhas, vendedores, regiões	Semanal ou sob demanda
Logs e eventos digitais	Streaming ou arquivos de log	clique, visualização, carrinho, evento_estoque, evento_atendimento	Tempo real ou micro-batch
APIs externas	API REST	feriados, clima, indicadores econômicos, localização	Diária ou semanal

As fontes relacionais fornecem o núcleo transacional da empresa. APIs de CRM e atendimento ampliam a visão sobre relacionamento com clientes. Planilhas representam dados de negócio frequentemente mantidos fora dos sistemas principais. Logs e eventos permitem capturar comportamento operacional. APIs externas enriquecem os dados com fatores de sazonalidade e contexto, úteis principalmente para previsão de demanda.

6. Arquitetura geral da solução

A arquitetura proposta segue o padrão Medallion e organiza o fluxo em etapas: fontes de dados, ingestão, armazenamento em Data Lake, transformação, validação, modelagem e consumo por IA. O Data Lake será implementado sobre armazenamento de objetos compatível com S3, utilizando MinIO no ambiente local ou S3 em ambiente de produção. O formato principal de armazenamento será Parquet, por ser colunar e adequado para cargas analíticas.

Tecnologias propostas

Função no pipeline	Tecnologia proposta	Justificativa
Containerização	Docker e Docker Compose	Permitem padronizar o ambiente e facilitar a reprodução dos serviços usados no pipeline.
Data Lake	MinIO / S3	Armazenamento de objetos para organizar as camadas Bronze, Silver e Gold.
Ingestão visual	Airbyte	Adequado para conectar bancos, APIs, arquivos e serviços SaaS com baixa necessidade de código.
Ingestão programática	Python + dlt	Permite criar pipelines customizados quando conectores prontos não atendem às regras de negócio.
Formato analítico	Parquet + Snappy	Formato colunar com compressão eficiente e schema embutido.
Transformação	dbt, DuckDB ou Apache Spark	dbt para transformações SQL e testes; DuckDB para análises locais; Spark para maior volume de dados.
Orquestração	Apache Airflow	Agendamento, dependência entre tarefas, logs e monitoramento de execução.
Qualidade de dados	Great Expectations ou testes dbt	Validação de schema, completude, unicidade, faixas válidas e regras de negócio.
Versionamento	GitHub	Controle de versão da documentação, diagramas e artefatos do projeto.
Consumo por IA	Python, scikit-learn, XGBoost, LightGBM, Prophet	Treinamento e avaliação de modelos preditivos e de segmentação.

Diagrama da arquitetura proposta




Figura 1 — Arquitetura proposta do pipeline de dados para IA aplicada a PMEs. Fonte: elaboração própria.

7. Camada Bronze

A camada Bronze representa a primeira área persistente do Data Lake. Seu objetivo é preservar os dados exatamente como chegaram das fontes, mantendo o maior nível possível de fidelidade ao dado original. Nessa camada não devem ocorrer limpezas de negócio, agregações ou enriquecimentos. A única intervenção prevista é a inclusão de metadados técnicos de rastreabilidade.

Características da Bronze

- armazenamento dos dados brutos em formato Parquet, JSON ou CSV, conforme origem e maturidade da fonte;
- particionamento por data de ingestão, sistema de origem e entidade;
- adição de metadados como fonte, data/hora de ingestão, versão do schema e identificador do lote;
- retenção do histórico de cargas para permitir auditoria e reprocessamento;
- separação física ou lógica por bucket/prefixo, como bronze/erp/vendas/ano=2026/mes=06/dia=18/.

Exemplo de metadados técnicos

Campo técnico	Descrição
_fonte	Sistema ou API de origem dos dados.
_ingerido_em	Timestamp UTC da ingestão.
_versao_schema	Versão do layout esperado para aquela entidade.
_id_lote	Identificador único da execução/carga.
_caminho_origem	Caminho, endpoint ou tabela original.
_checksum	Hash para verificação de integridade do arquivo ingerido.

No projeto, a Bronze será povoada por conectores Airbyte para sistemas padronizados, por scripts dlt para APIs ou regras customizadas e por rotinas de upload controlado para planilhas. Para dados de eventos, a arquitetura prevê uso de Kafka ou micro-batches, dependendo da maturidade da empresa e da necessidade de latência.

8. Camada Silver

A camada Silver transforma os dados brutos em dados confiáveis, integrados e consistentes. É nela que ocorrem as regras de padronização, qualidade, tratamento de dados ausentes, deduplicação e conformidade entre entidades. A Silver ainda não é necessariamente a camada final de consumo por IA, mas cria uma base limpa e integrada para modelagens posteriores.

Tratamentos propostos

Categoria de tratamento	Descrição	Exemplo
Padronização de tipos	Conversão de datas, números, moedas e booleanos.	data_venda em formato ISO, valor_total como decimal.
Deduplicação	Remoção de registros repetidos com base em chaves e timestamps.	Manter apenas o último cadastro válido do cliente.
Tratamento de nulos	Definição de regras por campo e por criticidade.	Telefone nulo pode ser aceito; id_cliente nulo invalida registro.
Normalização de categorias	Padronização de valores categóricos.	“finalizado”, “concluído” e “pago” mapeados para status padronizado.
Integração de entidades	Relacionamento entre clientes, vendas, produtos, atendimento e CRM.	Cliente único vinculado a pedidos, chamados e leads.
Mascaramento de PII	Proteção de dados pessoais quando não forem necessários para IA.	Hash de telefone ou e-mail para análises agregadas.
Validação de regras	Testes de integridade e consistência.	Pedido não pode ter valor negativo ou data futura.

Principais entidades Silver

- silver_clientes: cadastro único de clientes, com chaves padronizadas e dados de contato tratados;
- silver_produtos: catálogo de produtos com categorias, preços, margem e status;
- silver_vendas: histórico de pedidos e itens vendidos;
- silver_estoque: saldos, entradas, saídas e rupturas por produto;
- silver_atendimentos: mensagens, categorias, canais, sentimentos e resoluções;
- silver_crm: leads, oportunidades, etapas do funil e conversões;
- silver_calendario: feriados, datas comemorativas, dia da semana e sazonalidades.

9. Camada Gold

A camada Gold disponibiliza dados modelados para consumo por Analytics e Inteligência Artificial. Nela são criadas tabelas de fatos, dimensões e conjuntos de features para modelos de machine learning. A Gold deve ser estável, documentada e orientada ao uso final.

Datasets Gold propostos

Dataset Gold	Objetivo	Principais variáveis
gold_vendas_diarias	Base temporal para previsão de demanda.	data, produto, quantidade_vendida, receita, desconto, estoque, feriado, campanha.
gold_clientes_ia	Visão consolidada para segmentação e churn.	recência, frequência, ticket_médio, total_gasto, categoria_cliente, reclamações.
gold_features_churn	Features para classificação de risco de abandono.	dias_sem_compra, queda_frequência, interações_negativas, tickets_abertos.
gold_features_previsao_demanda	Features para modelos de forecast.	vendas_lag_7, vendas_lag_30, média_móvel, sazonalidade, ruptura, feriado.
gold_interacoes_cliente	Base para NLP e análise de atendimento.	mensagem, canal, intenção, sentimento, tempo_resposta, status_resolução.
gold_recomendacao_comercial	Base para recomendação de ações e ofertas.	perfil_cliente, produtos_comprados, produtos_relacionados, propensão_compra.

A camada Gold também deve conter documentação de dicionário de dados, regras de criação das features, janela temporal utilizada, periodicidade de atualização e limitações conhecidas. Isso reduz o risco de uso incorreto dos dados pelos modelos de IA.

10. Uso dos dados em algoritmos de IA

Os datasets da camada Gold serão utilizados em diferentes classes de algoritmos, conforme o objetivo de negócio. Para cada caso, é necessário garantir que os dados estejam no formato adequado, sem vazamento de informação do futuro para o passado, com variáveis consistentes e histórico suficiente para treinamento e validação.

Caso de uso	Algoritmos sugeridos	Requisitos dos dados
Previsão de demanda	Prophet, Random Forest, XGBoost, LightGBM	Histórico diário ou semanal de vendas, produto, calendário, rupturas, campanhas e variáveis defasadas.
Previsão de churn	Regressão Logística, Random Forest, XGBoost	Base rotulada com clientes que compraram ou deixaram de comprar, recência, frequência, valor e interações.
Segmentação de clientes	K-Means, DBSCAN, modelos hierárquicos	Variáveis comportamentais agregadas e escaladas, como frequência, ticket médio e categorias de consumo.
Classificação de atendimento	Modelos de NLP e classificadores supervisionados	Textos limpos, labels de intenção, sentimento, categoria do atendimento e status de resolução.
Recomendação comercial	Regras de associação, ranking ou modelos de propensão	Histórico de compras, perfil do cliente, produtos relacionados e resultado de campanhas anteriores.

Para modelos supervisionados, será necessário separar bases de treino, validação e teste, mantendo a ordem temporal nos casos de previsão de demanda e churn. Para NLP, os textos devem passar por etapas de limpeza, remoção de dados pessoais quando aplicável e padronização de labels. Para segmentação, variáveis numéricas devem ser analisadas quanto à escala e distribuição.

11. Qualidade de dados, testes e governança

A qualidade dos dados é um requisito essencial para que os modelos de IA gerem resultados confiáveis. O pipeline deve incluir validações automáticas em diferentes pontos do fluxo, especialmente na transição entre Bronze, Silver e Gold.

Dimensões de qualidade

Dimensão	Aplicação no projeto	Exemplo de regra
Compleitude	Verificar se campos obrigatórios estão preenchidos.	id_cliente e id_pedido não podem ser nulos.
Unicidade	Evitar registros duplicados.	Um pedido não deve aparecer duas vezes no mesmo lote.
Validade	Garantir domínio e formato correto.	status_venda deve pertencer a uma lista controlada.
Consistência	Checar coerência entre campos.	valor_total deve ser quantidade multiplicada pelo preço, ajustado por desconto.
Temporalidade	Garantir ordem e janela correta dos dados.	data_venda não pode ser futura.
Integridade referencial	Validar relacionamento entre tabelas.	id_produto em vendas deve existir no cadastro de produtos.
Privacidade	Proteger dados pessoais e sensíveis.	Telefone e e-mail podem ser mascarados quando não forem necessários.

Governança e segurança

- catálogo de dados com descrição de fontes, tabelas, campos e responsáveis;
- lineage para rastrear a origem e as transformações dos dados;
- controle de acesso por camada e por sensibilidade do dado;
- anonimização ou mascaramento de dados pessoais conforme a necessidade de uso;
- versionamento de schemas e modelos de transformação;
- logs de execução, erros e alertas para falhas de ingestão ou transformação.

12. Orquestração e operação

A orquestração do pipeline será realizada com Apache Airflow, responsável por agendar e monitorar tarefas de ingestão, transformação, validação e publicação dos datasets Gold. As dependências entre tarefas devem garantir que uma camada só seja processada após a conclusão e validação da camada anterior.

Fluxo operacional sugerido

1. Executar ingestões das fontes ERP, CRM, planilhas, WhatsApp e APIs externas.
2. Gravar arquivos brutos particionados na camada Bronze, com metadados técnicos.
3. Executar validações iniciais de schema e integridade dos arquivos recebidos.
4. Processar transformações Silver, aplicando limpeza, padronização e integração.
5. Executar testes de qualidade na Silver.
6. Gerar datasets Gold e tabelas de features para IA.
7. Executar validações finais na Gold.
8. Disponibilizar dados para notebooks, modelos de IA, dashboards ou APIs internas.
9. Registrar logs, métricas de execução, alertas e histórico de versões.

Métricas de monitoramento

- tempo de execução por DAG e por tarefa;
- quantidade de registros ingeridos por fonte;
- percentual de registros rejeitados por validação;
- volume armazenado por camada;
- atraso de atualização dos datasets Gold;
- número de falhas por fonte e por período;
- indicadores de qualidade dos dados por dataset.

13. Conclusão

O projeto demonstra como um pipeline de Engenharia de Dados pode viabilizar o uso de Inteligência Artificial em PMEs. A arquitetura proposta organiza dados dispersos em um fluxo estruturado, rastreável e governado, permitindo que informações originalmente espalhadas entre ERP, CRM, WhatsApp, planilhas e APIs externas sejam transformadas em datasets confiáveis para análise e modelagem preditiva.

A separação em camadas Bronze, Silver e Gold garante preservação dos dados brutos, aplicação controlada de transformações e disponibilização de bases prontas para consumo. A adoção de ferramentas open source e compatíveis com o ecossistema da disciplina, como Docker, MinIO, Airbyte, dlt, Parquet, dbt e Airflow, torna a proposta tecnicamente consistente e aderente às melhores práticas de Engenharia de Dados.

Por fim, a camada Gold conecta diretamente a Engenharia de Dados aos objetivos de IA: previsão de demanda, churn, segmentação, NLP e recomendação comercial. Com isso, o projeto não apenas descreve uma infraestrutura de dados, mas mostra como ela pode gerar valor real para pequenas e médias empresas por meio de decisões mais inteligentes e automatizadas.